

INSTITUT TEKNOLOGI SAINS BANDUNG (ITSB)

Lembaga Penelitian, Pengabdian dan Pengembangan Bisnis (LP3B)

ARSITEKTUR SISTEM DIGITALISASI KAKAO BERBASIS AI

Berau Coal Plantation Kalimantan Timur

Team Leader:	Asst. Prof. Dr. Eng. Ade Kurniawan
Workstation Target:	AMD Ryzen 7 9700X NVIDIA RTX 5070 12GB
Versi Dokumen:	v1.1 April 2026
Klasifikasi:	Dokumen Teknis Internal

Contents

1	Pendahuluan	2
1.1	Tujuan Arsitektur	2
2	Arsitektur Sistem End-to-End	2
3	Detail Tiap Lapisan Arsitektur	2
3.1	Edge Layer: Akuisisi dan Kompresi Citra di Smartphone	3
3.1.1	Proses Akuisisi Citra	3
3.1.2	Teknik Kompresi Citra Modern	3
3.2	Network Layer: Transmisi via Jaringan Seluler	4
3.3	Processing Layer: Workstation AI dengan GPU	4
3.3.1	Spesifikasi Workstation	4
3.3.2	Pipeline Inferensi AI pada Workstation	4
3.3.3	Arsitektur Model Transformer	5
3.4	Presentation Layer: Monitor dan Notifikasi	5
4	Perhitungan Kapasitas Inferensi Workstation	5
4.1	Parameter Perhitungan	5
4.2	Estimasi Throughput Inferensi	6
4.2.1	Skenario 1: Single-Image Inference (Latensi Rendah)	6
4.2.2	Skenario 2: Batched Inference (Throughput Tinggi)	6
4.2.3	Skenario 3: Throughput Maksimum (Batch Besar)	7
4.3	Konversi ke Kapasitas Request Operator	7
4.4	Ringkasan Kapasitas Inferensi	8
4.5	Analisis Bottleneck dan Pemanfaatan Resource	8
5	Arsitektur Software Stack	9
6	Arsitektur Keamanan dan Reliabilitas	9
7	Diagram Alur Data Lengkap	10
8	Estimasi Latensi End-to-End	10
9	Mockup Visual Aplikasi Mobile	10
9.1	Fitur Utama Aplikasi Mobile	11
10	Kesimpulan	12

1 Pendahuluan

Dokumen ini menyajikan arsitektur sistem secara lengkap dan mendetail untuk proyek **Digitalisasi Kakao Berbasis Artificial Intelligence** di Berau Coal Plantation, Kalimantan Timur. Sistem dirancang untuk mengidentifikasi kesehatan tanaman kakao meliputi analisis citra **batang** (*trunk/stem*), **daun** (*leaf*), dan **buah** (*pod/fruit*) secara otomatis menggunakan model deep learning berbasis **Transformer** dan **Attention Mechanism**.

Arsitektur mencakup seluruh alur kerja (*end-to-end pipeline*), dimulai dari akuisisi citra di lapangan oleh operator menggunakan smartphone, kompresi citra modern, transmisi melalui jaringan seluler, analisis AI pada workstation GPU, hingga penyampaian hasil diagnosis kembali ke operator.

1.1 Tujuan Arsitektur

Arsitektur ini dirancang untuk memenuhi beberapa tujuan utama: menyediakan pipeline akuisisi-inferensi-respons yang cepat dan efisien dengan latensi rendah; mengoptimalkan penggunaan bandwidth jaringan seluler di area perkebunan melalui kompresi citra mutakhir; memaksimalkan kapasitas inferensi workstation untuk melayani banyak operator secara simultan; serta menjamin kualitas diagnosis melalui model Transformer yang tervalidasi. Target penyakit yang dideteksi meliputi *Black Pod* (*Phytophthora palmivora*), *Vascular Streak Dieback* (VSD), serangan *Helopeltis*, dan defisiensi nutrisi.

2 Arsitektur Sistem End-to-End

Arsitektur sistem terdiri dari empat lapisan utama (*layer*): (1) **Edge Layer** (smartphone operator), (2) **Network Layer** (jaringan seluler), (3) **Processing Layer** (workstation GPU), dan (4) **Presentation Layer** (monitor & notifikasi). Gambar 1 menyajikan diagram arsitektur lengkap.




Figure 1: Arsitektur End-to-End Sistem Digitalisasi Kakao Berbasis AI — dari akuisisi citra oleh operator di lapangan hingga penyajian hasil diagnosis

3 Detail Tiap Lapisan Arsitektur

3.1 Edge Layer: Akuisisi dan Kompresi Citra di Smartphone

3.1.1 Proses Akuisisi Citra

Operator di lapangan menggunakan smartphone dengan kamera beresolusi ≥ 12 MP untuk mengambil citra bagian tanaman kakao. Aplikasi mobile (Android, dikembangkan dengan Kotlin/Flutter) menyediakan fitur *guided framing* yang memandu operator untuk mengambil gambar dengan posisi, jarak, dan pencahayaan yang optimal. Setiap citra disertai metadata berupa lokasi GPS, *timestamp*, kondisi cuaca, dan kode identitas tanaman.

Tiga jenis organ tanaman yang difoto meliputi:

- **Batang (*Trunk/Stem*):** Untuk deteksi gejala VSD, kanker batang, dan infeksi jamur.
- **Daun (*Leaf*):** Untuk klasifikasi Black Pod, Helopeltis, defisiensi nutrisi (N, P, K, Mg).
- **Buah (*Pod/Fruit*):** Untuk deteksi Black Pod pada buah, *Cocoa Pod Borer* (CPB), dan cacat fisik.

3.1.2 Teknik Kompresi Citra Modern

Sebelum ditransmisikan, citra dikompresi di sisi smartphone untuk menghemat bandwidth dan mempercepat transfer data. Sistem mengadopsi teknik kompresi terkini sebagaimana disajikan pada Tabel 1.

Table 1: Perbandingan Teknik Kompresi Citra Modern (2025–2026)

Format	Teknologi	Keunggulan	Rasio vs JPEG
AVIF (AV1 Image)	Intra-coding AV1, Alliance for Open Media	Kompresi superior, dukungan HDR & transparansi, <i>royalty-free</i> , didukung 93%+ browser, hardware decoding pada Android modern	~50% lebih kecil
HEIC/HEIF (H.265 Intra)	Intra-coding H.265/HEVC	Default di iOS & Android modern, kompresi 50% vs JPEG, dukungan HDR, encoding cepat	~50% lebih kecil
JPEG XL	JPEG Committee, lossless transcode	Lossy & lossless, bit-depth tinggi (32-bit), <i>backward compatible</i> , encoding cepat	~55% lebih kecil
JPEG AI	Neural network, JPEG Committee	End-to-end deep learning encoding-decoding, rasio kompresi sangat tinggi dengan kualitas perseptual terjaga	~60–70%+ lebih kecil
WebP	VP8 intra-coding, Google	Dukungan luas, fallback yang baik	~30% lebih kecil

Strategi Kompresi yang Dipilih

Sistem ini mengadopsi **AVIF** sebagai format kompresi utama karena keseimbangan terbaik antara rasio kompresi (~50% lebih kecil dari JPEG), kualitas visual, dan dukungan platform yang luas (Android & Web). HEIC digunakan sebagai fallback untuk perangkat Apple. Pipeline kompresi di smartphone:

1. **Resize** citra dari resolusi asli ($\sim 4000 \times 3000$) ke 1024×768 atau 1280×960 pixels (mempertahankan detail diagnostik yang cukup).
2. **Encode AVIF** dengan quality factor $q = 60-70$ (lossy, visually near-lossless untuk fitur patologis).
3. **Strip metadata** non-esensial, pertahankan GPS & timestamp.
4. Ukuran akhir per citra: **~200–500 KB** (vs ~2–4 MB untuk JPEG 12 MP asli).

3.2 Network Layer: Transmisi via Jaringan Seluler

Citra terkompresi ditransmisikan dari smartphone ke workstation melalui jaringan seluler (4G LTE / 5G jika tersedia di area Berau). Protokol komunikasi menggunakan **HTTPS** dengan TLS 1.3 untuk keamanan data. Arsitektur jaringan meliputi:

- **Protokol:** RESTful API via HTTPS (POST `/api/v1/predict` dengan *multipart/form-data*).
- **Kompresi transport:** HTTP/2 dengan Brotli atau gzip compression.
- **Retry & Queue:** Mekanisme retry otomatis dengan exponential backoff; antrian Redis untuk menangani burst request.
- **Mode Offline:** Citra disimpan secara lokal saat jaringan tidak tersedia dan disinkronisasi otomatis ketika koneksi pulih.

Estimasi waktu transmisi: untuk citra 400 KB pada jaringan 4G LTE dengan kecepatan efektif 5–15 Mbps, waktu upload berkisar ~0.2–0.6 detik per citra.

3.3 Processing Layer: Workstation AI dengan GPU

3.3.1 Spesifikasi Workstation

Spesifikasi Workstation AI Berau Coal Plantation	
Komponen	Spesifikasi
Processor (CPU)	AMD Ryzen 7 9700X 8 Cores / 16 Threads, 3.8 GHz base / 5.5 GHz boost, Zen 5 Architecture, 32 MB L3 Cache
GPU	NVIDIA GeForce RTX 5070 12 GB GDDR7, 192-bit bus, 672 GB/s bandwidth, 6,144 CUDA Cores, 192 Tensor Cores (5th Gen), 48 RT Cores (4th Gen), Blackwell Architecture, 988 AI TOPS (sparse), ~30.9 TFLOPS (FP16 CUDA), ~247 TFLOPS (FP16 Tensor, sparse), TDP 250W
Memori (RAM)	32 GB DDR5-6000 (2×16 GB, Dual Channel)
Penyimpanan	1 TB NVMe SSD (PCIe Gen 4, ~7,000 MB/s seq. read)
OS	Ubuntu 24.04 LTS / Windows 11 Pro
Software Stack	Python 3.11+, PyTorch 2.x, CUDA 12.x, TensorRT, FastAPI, Uvicorn, Redis

3.3.2 Pipeline Inferensi AI pada Workstation

Gambar 2 menunjukkan detail pipeline inferensi yang berjalan di workstation.




Figure 2: Pipeline inferensi detail pada workstation dari penerimaan request hingga pengiriman respons.

3.3.3 Arsitektur Model Transformer

Gambar 3 mengilustrasikan arsitektur internal model Transformer yang digunakan untuk klasifikasi dan deteksi penyakit kakao.




Figure 3: Arsitektur internal model Transformer untuk klasifikasi & deteksi penyakit tanaman kakao. Model kandidat: ViT-Base, Swin-T/S, DETR, DeiT, CaiT.

3.4 Presentation Layer: Monitor dan Notifikasi

Hasil analisis ditampilkan melalui dua kanal:

1. **Dashboard Monitor (Workstation):** Tampilan real-time pada monitor workstation berupa dashboard web (React.js) yang menampilkan statistik analisis, distribusi penyakit per blok kebun, tren temporal, dan Grad-CAM *heatmap* yang menunjukkan area citra yang menjadi fokus model dalam menentukan diagnosis.
2. **Notifikasi ke Operator:** Hasil diagnosis dikirim kembali ke smartphone operator dalam bentuk JSON response yang diterjemahkan oleh aplikasi mobile menjadi tampilan visual: kategori penyakit, *confidence score* (persentase keyakinan), tingkat keparahan, dan rekomendasi tindakan. Push notification digunakan untuk alert penyakit kritis.

4 Perhitungan Kapasitas Inferensi Workstation

Bagian ini menyajikan perhitungan kapasitas workstation dalam melayani request inferensi dari banyak operator smartphone secara simultan.

4.1 Parameter Perhitungan

Parameter Kunci Perhitungan Throughput

Parameter	Nilai & Justifikasi
GPU	NVIDIA RTX 5070, Blackwell, 12 GB GDDR7, 192 Tensor Cores 5th Gen, 988 AI TOPS (sparse), ~30.9 TFLOPS (FP16 CUDA), ~247 TFLOPS (FP16 Tensor, sparse)
Model Referensi	Swin Transformer-Tiny (Swin-T), ~28M parameter
Input Size	$224 \times 224 \times 3$ pixels
Precision	FP16 (TensorRT optimized) / INT8
VRAM per model	~200–500 MB (FP16, Swin-T)
VRAM tersedia	~10 GB (dari 12 GB total, dikurangi OS overhead)
Perbandingan generasi	RTX 5070 ~20–30% lebih cepat dari RTX 4070 pada tugas Computer Vision berkat Tensor Cores 5th Gen dan bandwidth GDDR7

4.2 Estimasi Throughput Inferensi

Berdasarkan benchmark Computer Vision pada GPU kelas RTX 5070 (Blackwell, 6,144 CUDA Cores, 192 Tensor Cores) dengan arsitektur Swin Transformer dan pengaturan batch yang relevan, kita dapat mengestimasi throughput sebagai berikut:

4.2.1 Skenario 1: Single-Image Inference (Latensi Rendah)

Untuk skenario real-time di mana setiap request diproses segera (batch size = 1):

$$\begin{aligned}
 t_{\text{inference}} &\approx 12\text{--}18 \text{ ms per citra (Swin-T, TensorRT FP16)} \\
 t_{\text{preprocess}} &\approx 3\text{--}5 \text{ ms (decode AVIF + resize + normalize)} \\
 t_{\text{postprocess}} &\approx 1\text{--}2 \text{ ms (softmax + JSON)} \\
 t_{\text{total}} &\approx 16\text{--}25 \text{ ms per request} \\
 \text{Throughput}_{\text{single}} &= \frac{1000}{t_{\text{total}}} \approx \frac{1000}{20} \approx \mathbf{50} \text{ citra/detik}
 \end{aligned} \tag{1}$$

4.2.2 Skenario 2: Batched Inference (Throughput Tinggi)

Untuk skenario batch processing di mana beberapa request dikumpulkan dan diproses secara bersamaan (batch size = 8–16):

$$\begin{aligned}
 t_{\text{batch}}(B=8) &\approx 40\text{--}50 \text{ ms untuk 8 citra} \\
 \text{Throughput}_{B=8} &= \frac{8}{0.045} \approx \mathbf{178} \text{ citra/detik}
 \end{aligned} \tag{2}$$

$$\begin{aligned}
 t_{\text{batch}}(B=16) &\approx 70\text{--}90 \text{ ms untuk 16 citra} \\
 \text{Throughput}_{B=16} &= \frac{16}{0.080} \approx \mathbf{200} \text{ citra/detik}
 \end{aligned} \tag{3}$$

4.2.3 Skenario 3: Throughput Maksimum (Batch Besar)

Berdasarkan estimasi dengan batch size = 64 pada image size 224×224 (dibatasi oleh VRAM 12 GB):

$$\text{Throughput}_{\max} \approx 800\text{--}1,200 \text{ citra/detik} \quad (\text{Swin-T, FP16, batch}=64) \quad (4)$$

Ini merupakan batas atas praktis mengingat keterbatasan VRAM 12 GB yang membatasi batch size maksimum dibanding GPU dengan VRAM lebih besar. Untuk model ringan Swin-T ($\sim 28\text{M}$ parameter, $\sim 500 \text{ MB FP16}$), VRAM 12 GB masih sangat memadai untuk operasi inferensi dengan batch sedang.

4.3 Konversi ke Kapasitas Request Operator

Dalam skenario operasional di lapangan, kapasitas request perlu mempertimbangkan pola penggunaan realistis:

Kalkulasi Kapasitas Operator Harian

Asumsi pola kerja operator:

- Setiap operator mengambil $\sim 5\text{--}10$ foto per tanaman (batang, daun, buah dari sudut berbeda).
- Setiap operator memeriksa $\sim 30\text{--}50$ tanaman per hari.
- Total foto per operator per hari: $\sim 150\text{--}500$ citra.
- Jam kerja efektif: 8 jam (28,800 detik).
- Pola: bursty foto diambil berkelompok, bukan merata sepanjang hari.

Kapasitas workstation dengan Skenario 2 (Batched, Produksi):

Throughput produksi ≈ 150 citra/detik (konservatif, termasuk overhead)

Kapasitas per jam = $150 \times 3,600 = 540,000$ citra/jam

Kapasitas per hari (8 jam) = $540,000 \times 8 = 4,320,000$ citra/hari

Jumlah operator simultan yang dapat dilayani:

$$\begin{aligned} \text{Operator}_{\max} &= \frac{\text{Kapasitas per hari}}{\text{Foto per operator per hari}} \\ &= \frac{4,320,000}{500} = 8,640 \text{ operator/hari} \quad (\text{batas atas}) \end{aligned}$$

Secara realistis, mempertimbangkan *burst traffic* dan latensi jaringan:

Peak concurrent requests ≈ 150 request/detik

$$\text{Operator simultan (peak)} \approx \frac{150}{\text{avg. req/s per operator}} = \frac{150}{0.1} = 1,500 \text{ operator simultan}$$

Dengan asumsi setiap operator mengirim rata-rata 1 foto setiap 10 detik saat aktif (0.1 req/s), workstation mampu melayani hingga **$\sim 1,500$ operator secara simultan tanpa degradasi latensi yang signifikan**. Kapasitas ini jauh melampaui kebutuhan operasional perkebunan kakao Berau Coal yang diperkirakan memerlukan puluhan hingga ratusan operator.

4.4 Ringkasan Kapasitas Inferensi

Table 2: Ringkasan Kapasitas Inferensi Workstation RTX 5070 untuk Swin Transformer

Skenario	Batch Size	Throughput	Latensi per Citra
Real-time (single)	1	~50 citra/detik	~20 ms
Batched (produksi)	8	~178 citra/detik	~45 ms (avg)
Batched (produksi)	16	~200 citra/detik	~80 ms (avg)
Max throughput	64	~800–1,200 citra/detik	~53–80 ms (avg)
Kapasitas operasional harian (8 jam):			
Batched produksi (B=8)		~4,320,000 citra/hari	
Operator simultan (peak)		~1,500 operator	

4.5 Analisis Bottleneck dan Pemanfaatan Resource

Table 3: Analisis Bottleneck pada Setiap Komponen Workstation

Komponen	Spesifikasi	Konsumsi	Status
GPU VRAM	12 GB GDDR7	Model Swin-T ~0.5 GB + batch buffer ~1 GB	Cukup ; dapat memuat 3 model organ sekaligus (~1.5 GB) dengan sisa VRAM untuk batch buffer
GPU Compute	30.9 TFLOPS FP16, 247 TFLOPS Tensor (sparse)	Inference FP16 optimal	Bottleneck utama (positif) ; TensorRT mengoptimalkan utilisasi Tensor Cores 5th Gen
System RAM	32 GB DDR5	Pre-processing queue, image buffer	Cukup ; ~8 GB untuk OS + ~24 GB untuk buffer/queue
CPU	Ryzen 7 9700X, 8C/16T	Pre/post-processing, API handling	Cukup ; async workers (Uvicorn) paralel, 8 cores memadai untuk workload API
SSD Storage	1 TB NVMe PCIe 4	Model weights, log, temporary images	Sangat Cukup ; 7 GB/s read
Network I/O	Gigabit Ethernet / 10 GbE	API request/response	Cukup untuk skenario ini

5 Arsitektur Software Stack




Figure 4: Arsitektur software stack sistem AI Kakao dari hardware hingga presentation layer.

6 Arsitektur Keamanan dan Reliabilitas

Sistem ini menerapkan beberapa lapisan keamanan dan mekanisme reliabilitas:

1. **Enkripsi End-to-End:** Semua komunikasi menggunakan HTTPS dengan TLS 1.3; data citra dienkripsi saat transit.
2. **Autentikasi:** Token JWT (*JSON Web Token*) untuk autentikasi operator; API key untuk akses endpoint.
3. **Rate Limiting:** Nginx rate limiter untuk mencegah abuse; maksimal 100 request per menit per operator.
4. **Backup & Recovery:** Backup dataset harian ke SSD eksternal/NAS; model checkpoint disimpan secara berkala.
5. **Health Monitoring:** Grafana + Prometheus untuk monitoring GPU utilization, API latency, error rate, dan queue depth.
6. **Failover:** Mekanisme *graceful degradation* jika GPU overloaded, request di-queue dan operator diberi notifikasi estimasi waktu tunggu.

7 Diagram Alur Data Lengkap

Gambar 5 menyajikan diagram alur data lengkap dari sudut pandang satu citra mulai dari pengambilan di lapangan hingga diagnosis diterima operator.




Figure 5: Diagram alur data lengkap 13 langkah dari akuisisi citra hingga logging ke database.

8 Estimasi Latensi End-to-End

Tabel 4 menyajikan estimasi latensi menyeluruh dari perspektif operator.

Table 4: Estimasi Latensi End-to-End (Operator Perspective)

No	Tahap	Latensi (ms)	Keterangan
1	Kompresi AVIF di HP	50–150	Hardware encoder Android
2	Upload via 4G LTE (400 KB)	200–600	Tergantung sinyal di Berau
3	API receive & validate	<5	FastAPI async
4	Decode AVIF + Pre-process	5–10	CPU, libavif + OpenCV
5	GPU inference (Swin-T)	12–18	TensorRT FP16, batch=1
6	Post-processing	1–2	Softmax, Grad-CAM
7	Response generation	<2	JSON serialization
8	Download result ke HP	50–150	JSON ~2–5 KB, sangat cepat
Total Latensi End-to-End		~0.3–1.0 detik	Dominan: upload via jaringan

Bottleneck utama bukan pada inferensi GPU (~12–18 ms) melainkan pada latensi jaringan seluler (upload citra ~200–600 ms). Ini menunjukkan bahwa workstation RTX 5070 memiliki kapasitas komputasi yang memadai untuk skenario ini, dengan ruang yang cukup untuk scaling ke lebih banyak operator.

9 Mockup Visual Aplikasi Mobile

Aplikasi mobile **AI Kakao** merupakan antarmuka utama bagi operator di lapangan. Gambar 6 menyajikan mockup empat layar utama: *Home/Dashboard*, *Capture & Guided Framing*, *Hasil Diagnosis*, dan *Riwayat Inspeksi*. Desain mengutamakan kemudahan penggunaan (*ease-of-use*) bagi operator perkebunan dengan navigasi minimal, ikon besar, dan indikator warna yang intuitif.




Figure 6: Mockup visual empat layar utama aplikasi mobile AI Kakao: (a) Dashboard ringkasan dengan statistik harian, (b) Kamera dengan *guided framing* dan pemilihan organ tanaman, (c) Tampilan hasil diagnosis lengkap dengan Grad-CAM overlay, tingkat keparahan, dan rekomendasi tindakan, (d) Riwayat inspeksi dengan filter dan pencarian.

9.1 Fitur Utama Aplikasi Mobile

Aplikasi mobile dirancang dengan prinsip *field-first UX*, yaitu antarmuka yang dioptimalkan untuk kondisi lapangan perkebunan:

1. **Guided Framing System:** Overlay visual pada layar kamera yang memandu operator untuk memposisikan kamera pada jarak dan sudut optimal. Sistem memberikan indikator real-time (hijau = posisi baik, kuning = perlu penyesuaian) untuk memastikan kualitas citra yang konsisten.
2. **Organ Selector (Batang/Daun/Buah):** Operator memilih jenis organ tanaman sebelum mengambil foto, sehingga sistem otomatis merutekan citra ke model klasifikasi yang sesuai dan menggunakan set label penyakit yang relevan.
3. **Diagnosis Instan dengan Grad-CAM:** Hasil analisis ditampilkan dalam <2 detik, dilengkapi overlay *heatmap* Grad-CAM pada citra asli yang menunjukkan area spesifik yang menjadi dasar keputusan model. Hal ini meningkatkan kepercayaan operator terhadap diagnosis AI.
4. **Sistem Rekomendasi Tindakan:** Setiap diagnosis disertai rekomendasi penanganan berbasis *severity level* yang terstruktur, mulai dari monitoring berkala (keparahan rendah), aplikasi fungisida/pestisida (sedang), hingga eskalasi ke agronomis (tinggi/kritis).
5. **Mode Offline dengan Auto-Sync:** Seluruh citra dan metadata disimpan secara lokal saat jaringan tidak tersedia. Ketika koneksi pulih, data secara otomatis diunggah dan diproses oleh server, dengan hasil diagnosis dikirim kembali sebagai *push notification*.
6. **Geo-Tagging dan Pemetaan:** Setiap inspeksi otomatis ditandai koordinat GPS, memungkinkan visualisasi spasial distribusi penyakit pada peta blok kebun melalui fitur “Peta” di navigasi bawah.

10 Kesimpulan

Arsitektur sistem digitalisasi kakao berbasis AI ini dirancang sebagai pipeline end-to-end yang efisien, mulai dari akuisisi citra di lapangan oleh operator menggunakan smartphone, kompresi modern (AVIF), transmisi via jaringan seluler, hingga analisis AI berbasis Transformer pada workstation GPU, dengan hasil dikembalikan ke operator dan ditampilkan pada dashboard.

Aplikasi mobile AI Kakao menyediakan antarmuka intuitif bagi operator lapangan dengan fitur *guided framing*, pemilihan organ tanaman (batang/daun/buah), diagnosis instan dengan visualisasi Grad-CAM, serta sistem rekomendasi tindakan berbasis tingkat keparahan. Mode offline dengan auto-sync dan geo-tagging memastikan operabilitas di kondisi lapangan perkebunan yang menantang.

Strategi training mengadopsi paradigma tiga fase: *pre-training* dengan ImageNet dan dataset tanaman publik di ITSB, *domain-specific fine-tuning* menggunakan 10,000–16,000 citra kakao berlabel dari Berau Coal dengan teknik *progressive unfreezing*, serta *continuous learning* pasca-handover yang memungkinkan model terus berkembang secara mandiri. Prosedur handover yang terstruktur—meliputi penyerahan workstation, model terlatih, Docker container, source code, dataset, dokumentasi, dan workshop 3–5 hari—menjamin keberlangsungan operasi AI tanpa ketergantungan jangka panjang terhadap ITSB.

Workstation dengan spesifikasi AMD Ryzen 7 9700X dan NVIDIA RTX 5070 12GB memiliki kapasitas inferensi yang memadai: ~50 citra/detik pada mode real-time (batch=1) hingga ~200 citra/detik pada mode batched (batch=16), atau setara melayani hingga ~1,500 operator secara simultan pada saat peak. Dalam operasi harian 8 jam, workstation mampu memproses lebih dari 4 juta citra—jauh melampaui kebutuhan operasional perkebunan kakao yang diperkirakan memerlukan puluhan hingga ratusan operator.

Bottleneck utama sistem terletak pada latensi jaringan seluler di area perkebunan, bukan pada kapasitas komputasi workstation. Meskipun RTX 5070 memiliki VRAM lebih terbatas (12 GB) dibandingkan GPU kelas atas, kapasitas ini sangat memadai untuk model Swin-T (~28M parameter, ~500 MB FP16) dengan sisa VRAM yang cukup untuk memuat ketiga model organ (batang, daun, buah) secara simultan. Kombinasi arsitektur teknis yang efisien, strategi transfer learning yang teruji, dan mekanisme continuous learning menjadikan sistem ini sebagai solusi jangka panjang yang mandiri dan berkelanjutan untuk digitalisasi manajemen kesehatan tanaman kakao di Berau Coal Plantation.